

Regresyon & OLS

Regresyon

- Regresyon analizi, bir ya da daha fazla bağımsız değişken (predictor / feature / X'ler) kullanarak, bir bağımlı değişkeni (target / Y) modellemeyi sağlayan bir tekniktir. Amaç — bağımsız değişkenler ile hedef değişken arasındaki ilişkiyi nicel olarak ifade eden bir “denklem” bulmaktır.
- Basit doğrusal regresyonda bu denklem genelde şöyle yazılır:
 - $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x + \varepsilon$
 - $\hat{\beta}_0$: sabit terim (intercept)
 - $\hat{\beta}_1 x$: x'in y üzerindeki etkisini gösteren katsayı (slope)
- ε ise hata / residual terimidir — “modelin açıklayamadığı / rastgele kısmı” (noise, gözlem hatası vb) .
- Çoklu regresyonda — bir bağımlı değişken (Y) ve birden fazla bağımsız değişken ($X_1, X_2, \dots, X_p$) varsa — model şu genel denklem ile ifade edilir:
 - $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p + \varepsilon$
 - y: bağımlı değişken (tahmin etmek istediğimiz değişken)
 - $X_1, X_2, \dots, X_p$: bağımsız değişkenler / özellikler / predictor'lar
 - $\hat{\beta}_0$: intercept / sabit terim — tüm X'ler 0 iken Y'nin alacağı beklenen değer
 - $\hat{\beta}_1, \hat{\beta}_2, \dots, \hat{\beta}_p$: her bir X'in Y üzerindeki “katsayı”sı — diğer değişkenler sabitken, o değişkende bir birimlik değişim olursa Y'de beklenen değişim miktarı
 - ε : hata / residual / “modelin açıklayamadığı / rastgele kısmı” (noise, gözlem hatası vb)

OLS Regresyon Nedir? *OLS = Ordinary Least Squares = En Küçük Kareler Yöntemi*, doğrusal regresyonun katsayılarını bulmak için kullanılan matematiksel yöntemdir.

Ordinary Least Squares (OLS) Regresyon Varsayımları

1. Modelin parametrelerine göre lineer olması

- Model denklemi, $\hat{y} = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \hat{\beta}_2 x_2 + \dots + \hat{\beta}_p x_p + \varepsilon$ biçiminde olmalı, yani katsayılarla lineer bir yapı içermeli.
- X'lerin dönüşüm vb ile değil, parametrik katsayılarla çarpılan değişkenler olması
 | Model | OLS için uygun mu? | Neden | | ----- | ----- |
 ----- | | $(Y = \beta_0 + \beta_1 X)$ | ✓ | β lineer | | $(Y = \beta_0 + \beta_1 X^2)$ | ✓ | β lineer |
 | $(Y = \beta_0 + \beta_1 \ln(X))$ | ✓ | β lineer | | $(Y = \beta_0 + \beta_1 X + \beta_2 X^2)$ | ✓ | β lineer |
 | $(Y = X^{\beta_1})$ | x | β lineer değil | | $(Y = e^{\beta_1 X})$ | x | β lineer değil |
 | $(Y = \sin(\beta_1 X))$ | x | β lineer değil |

2. Hata (residual / error) terimlerinin beklenen değeri 0

- Yani $E[\varepsilon]=0$ Bu, modelin – ortalamada – tahmin hatasının sıfır olmasını garantiler.
- Bu varsayım, sabit terim (intercept) eklendiğinde genelde sağlanabilir.

3. Hata terimleri ile bağımsız değişkenler arasında ilişki / korelasyon olmaması (Exogeneity)

- Yani, X'ler hata terimi ile ilişkisiz olmalı; hata terimleri, gözlemler bağımsız olarak dağılmış olmalı.
- Eğer bu ihlal edilirse — örneğin ölçüm hatası, omitted variable bias, endojenlik vs varsa — β katsayılarının tahminleri yanlı olabilir.

4. Homoskedastisite — Hataların sabit varyanslı olması

- Tüm gözlemler için residual'ların varyansı aynı / sabit olmalı. Hata değişkenliği (variance) değişkenlere göre artıp azalmamalı.
- Eğer varyans sabit değilse (heteroskedasticity), standart hata / güven aralığı & test sonuçları güvenilir olmaz.

5. Hata terimleri birbirinden bağımsız olmalı — serial correlation / autocorrelation olmamalı

- Özellikle zaman serisi ya da ardışık verilerde, residual'lar arasında korelasyon olmamalı. Bu, modelin yapısını ve tahmin gücünü bozar.

6. Bağımsız değişkenler arasında multicollinearity (çoklu doğrusal bağlılık) olmamalı / makul düzeyde olmalı

- Özellikle çoklu regresyonda: X'ler birbirine çok yüksek korelasyonda olmamalı; yoksa katsayı tahminleri kararsız, yorum zor olur.

7. (İsteğe bağlı) Hataların normal dağılım göstermesi

- Özellikle p-value, güven aralığı, hipotez testleri için residual'ların yaklaşık normal dağılım göstermesi beklenir. Bu varsayım, OLS'in "en iyi lineer unbiased estimator (BLUE)" özelliği için değil ama istatistiksel çıkarımlar için önemlidir.

```
In [3]: import numpy as np
import pandas as pd

np.random.seed(42)

n = 200

tv = np.random.uniform(0, 300, n)           # TV reklam bütçesi (bin TL)
radio = np.random.uniform(0, 50, n)         # Radyo reklam bütçesi
social = np.random.uniform(0, 80, n)        # Sosyal medya reklam bütçesi

# Gerçek (bilinen) ilişki: Sales = 5 + 0.04*tv + 0.3*radio + 0.2*social +
noise = np.random.normal(0, 3, n)           # normal dağılmış hata
sales = 5 + 0.04*tv + 0.3*radio + 0.2*social + noise

df = pd.DataFrame({
    "TV": tv,
    "Radyo": radio,
    "Sosyal": social,
    "Satis": sales
})
```

```
})
```

```
df.head()
```

```
Out[3]:
```


	TV	Radyo	Sosyal	Satis
0	112.362036	32.101582	8.249910	19.184165
1	285.214292	4.206998	72.204233	29.732899
2	219.598183	8.081436	40.420190	23.971305
3	179.597545	44.927709	66.116597	35.779807
4	46.805592	30.321453	25.603968	19.428505

```
In [6]: # Keşifsel Analiz (EDA)
```

```
import matplotlib.pyplot as plt
import seaborn as sns
```

```
sns.pairplot(df, x_vars=["TV", "Radyo", "Sosyal"], y_vars="Satis", height=10)
plt.show()
```

```
df.describe().T
```



```
Out[6]:
```

	count	mean	std	min	25%	50%	75%	max
TV	200.0	145.201870	88.467429	1.656635	68.574724	148.345876	227.057885	285.214292
Radyo	200.0	25.218757	14.650060	0.253079	13.073125	27.081994	37.109966	72.204233
Sosyal	200.0	41.653823	24.584704	0.867012	20.441625	42.031958	64.889191	66.116597
Satis	200.0	26.525977	7.604660	6.768209	21.505461	26.213765	31.880847	35.779807

```
In [12]: import statsmodels.api as sm

X = df[["TV", "Radyo", "Sosyal"]]
y = df["Satis"]

# Sabit terim (intercept) ekleniyor
X_const = sm.add_constant(X)

model = sm.OLS(y, X_const).fit()
print(model.summary())
```

OLS Regression Results

```

=====
====
Dep. Variable:          Satis    R-squared:
0.841
Model:                  OLS      Adj. R-squared:
0.838
Method:                 Least Squares    F-statistic:          3
45.2
Date:                   Sat, 06 Dec 2025    Prob (F-statistic):      6.07
e-78
Time:                   18:18:27    Log-Likelihood:         -50
5.23
No. Observations:      200    AIC:                    1
018.
Df Residuals:          196    BIC:                    1
032.
Df Model:               3
Covariance Type:       nonrobust
=====
=====

```

```

=====
====
              coef      std err          t      P>|t|      [0.025      0.
975]
-----
----
const         4.8315      0.714       6.771      0.000       3.424
6.239
TV             0.0396      0.002      16.122      0.000       0.035
0.044
Radyo          0.2849      0.015      19.101      0.000       0.255
0.314
Sosyal         0.2105      0.009      23.668      0.000       0.193
0.228
=====
=====

```

```

=====
====
Omnibus:          0.785    Durbin-Watson:
1.879
Prob(Omnibus):    0.675    Jarque-Bera (JB):
0.740
Skew:             0.148    Prob(JB):
0.691
Kurtosis:         2.961    Cond. No.
578.
=====
=====

```

Notes:

[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

1. Üst Bilgiler

Dep. Variable: Satis - Bağımlı değişkenin adı. Bu modelde Satis değerleri tahmin ediliyor.

Model: OLS - Kullanılan yöntem: Ordinary Least Squares (En Küçük Kareler).

Method: Least Squares - Katsayılar, hata kareleri toplamını minimize edecek şekilde bulunmuştur.

Date / Time - Analizin yapıldığı tarih ve saat.

No. Observations: 200 - Toplam gözlem sayısı: 200.

Df Residuals: 196 - Residual (artık) serbestlik derecesi $df_{resid} = n - p - 1 = 200 - 3 - 1 = 196$ p
-> bağımsız değişken sayısı.

Df Model: 3 - Üç bağımsız değişken kullanılmış (TV, Radyo, Sosyal Medya).

Covariance Type: nonrobust - Klasik hata terimi varsayımlarına göre standart hatalar hesaplanmış.

2. Katsayı Tablosu (Coefficient Table)

Değişken	coef	std err	t	P> t	95% CI
const ($\beta_0 = 4.8315$)					
TV ($\beta_1 = 0.0396$)					
Radyo ($\beta_2 = 0.2849$)					
Sosyal ($\beta_3 = 0.2105$)					

const ($\beta_0 = 4.8315$) - Hiç reklam yapılmaya bile satışların ortalama 4.83 birim olacağı tahmin edilir.

TV ($\beta_1 = 0.0396$) - TV reklam bütçesi 1 birim arttığında, satışlar ortalama 0.0396 birim artar (diğer değişkenler sabitken). P-değeri = 0.000 → İstatistiksel olarak çok anlamlı. TV reklamı satış üzerinde gerçek ve güçlü bir etkiye sahip.

Radyo ($\beta_2 = 0.2849$) - Radyo bütçesi 1 birim arttığında, satış ortalama 0.2849 birim artıyor. P-değeri = 0.000 → Çok anlamlı bir değişken. Radyo reklamının TV'den daha yüksek katsayıya sahip olması - Bir birimlik bütçe artışının satışa etkisi daha büyük.

Sosyal ($\beta_3 = 0.2105$) - Sosyal medya reklam bütçesi 1 birim arttığında, satış ortalama 0.2105 birim artar. P-değeri = 0.000 → Çok anlamlı.

std err - Her katsayının tahmin belirsizliğidir. Ne kadar küçükse, katsayı o kadar güvenilirdir.

t - t ne kadar büyükse, katsayı o kadar anlamlıdır.

- t değeri ne kadar büyükse:
 - p-değeri o kadar küçük olur
 - katsayının sıfır olma olasılığı o kadar düşer
 - değişken daha anlamlıdır

[0.025, 0.975] (Güven aralığı) - Her katsayının %95 güven aralığı.

3. Model Uyum Ölçümleri (Model Fit Metrics)

R-squared = 0.841 - Model bağımlı değişkendeki varyansın %84.1'ini açıklıyor.

Adj. R-squared = 0.838 - Gereksiz değişken eklenmesinden etkilenmez. 0.838 de oldukça yüksek. Model sağlam.

F-statistic = 345.2 - Modeldeki tüm bağımsız değişkenlerin toplam etkisinin anlamlı olup olmadığını test eder.

Prob (F-statistic) = 6.07e-78 F testinin p-değeri aşırı küçük.

- Model genel olarak çok anlamlı.
- En az bir bağımsız değişken Y'yi açıklıyor.

Durbin-Watson = 1.879 - DW ≈ 2 ise residual'larda otokorelasyon yoktur.

- Otokorelasyon problemi görünmüyor.
- Hata terimleri bağımsız.

Jarque-Bera (JB) = 0.740 ; Prob(JB) = 0.691 - JB testi residual'ların normal dağılıp dağılmadığını test eder. residual normalitesi testi. $p > 0.05 \rightarrow$ normal dağılıma uygun.

Omnibus test = 0.785 ; Prob(Omnibus) = 0.675 - residual normalitesi testi. $p > 0.05 \rightarrow$ normal dağılıma uygun.

Skew = 0.148 - Hataların simetrik olduğunu gösterir (skew ≈ 0 iyi).

Kurtosis = 2.961 - Normal dağılımın kurtosis'i 3'tür. $\rightarrow 2.96 \rightarrow$ normal dağılıma oldukça yakın.

Cond. No. = 578 Bu, bağımsız değişkenler arasında multicollinearity olup olmadığını gösteren kaba bir ölçüdür.

- 30–100 $\rightarrow$ hafif
- 100–1000 $\rightarrow$ orta
- 1000 $\rightarrow$ ciddi

578 $\rightarrow$ belirli düzeyde multicollinearity olabilir ama kritik değil. (VIF ile analiz edilebilir)

Log-Likelihood: -505.23 - modelin gözlenen veriyi ne kadar iyi açıkladığını ölçen bir olasılık skorudur. Negatif olması normaldir — logaritma alınan ihtimaller çok küçük olduğu için.

Burada elde edilen değer tek başına bir şey ifade etmez. Ancak farklı modelleri karşılaştırırken anlam kazanır. daha yüksek LL $\rightarrow$ daha iyi model

AIC:1018 - AIC (Akaike Information Criterion).

- $AIC=2k-2\log(L)$ k: ahmin edilen parametre sayısı L:likelihood (olasılık)
- Modelin veriyi iyi açıklamasını ister (LL yüksek olsun)
- Ama çok fazla parametre kullanılmasına ceza verir (basit model ister)
- Daha küçük AIC = daha iyi model
- Bu yüzden AIC mutlak değer olarak değil, modeller arasında karşılaştırma için kullanılır.

BIC:1032 - 3. BIC (Bayesian Information Criterion)

- $BIC=k\ln(n)-2\log(L)$

- BIC, AIC'ye benzer ama parametre sayısına daha ağır ceza verir
- Özellikle fazla değişken içeren modelleri daha çok "uyarır"
- Daha küçük BIC = daha iyi model

Bu model için:

1. LL tek başına anlamlı değil → diğer modellerle karşılaştırınca anlam kazanacak
2. AIC ve BIC — modelin karmaşıklık + açıklama gücü dengesi
3. AIC < BIC olduğu için model makul düzeyde karmaşık
4. Başka modellerle karşılaştırınca işe yarayacak

AIC vs BIC: Hangisini kullanmalı

Ölçüt	Ne ister?	Ne zaman kullanılır?
AIC	Tahmin hatasını minimize eden modeli seçer	Makine öğrenmesi, tahmin problemleri
BIC	Gerçek modeli bulmayı amaçlar	Ekonometrik modelleme, bilimsel açıklama

Özet

- Log-Likelihood modelin veriyi ne kadar iyi açıkladığını ölçer (yüksek → iyi).
- AIC açıklama gücü + basitlik dengesini ölçer (düşük → iyi).
- BIC AIC'ye benzer ama gereksiz değişkene daha fazla ceza verir (düşük → iyi).
- Bu değerler modelleri karşılaştırmak için kullanılır; tek başlarına anlamlı değildir.

```
In [14]: # Artıkların (Residuals) Hesaplanması
df["y_pred"] = model.predict(X_const)
df["residuals"] = df["Satis"] - df["y_pred"]
df
```

```
Out[14]:
```


	TV	Radyo	Sosyal	Satis	y_pred	residuals
0	112.362036	32.101582	8.249910	19.184165	20.156730	-0.972565
1	285.214292	4.206998	72.204233	29.732899	32.508621	-2.775722
2	219.598183	8.081436	40.420190	23.971305	24.326987	-0.355682
3	179.597545	44.927709	66.116597	35.779807	38.649864	-2.870057
4	46.805592	30.321453	25.603968	19.428505	20.709543	-1.281037
...	...	...	...	...	...	...
195	104.762872	46.537866	37.916931	32.823880	30.213064	2.610816
196	217.786704	42.920638	53.404619	42.815452	36.912875	5.902576
197	269.133078	21.449701	13.785590	28.337047	24.488133	3.848914
198	266.125927	37.543553	15.383122	29.178061	29.290040	-0.111979
199	233.962664	37.727144	3.269489	23.010970	25.520475	-2.509505

200 rows × 6 columns

In [16]: *# Lineerlik Varsayımı – Fitted vs Residual Plot*

```
plt.figure(figsize=(7,5))
plt.scatter(df["y_pred"], df["residuals"])
plt.axhline(0, color="red", linestyle="--")
plt.xlabel("Tahmin edilen değerler (Fitted)")
plt.ylabel("Artıklar (Residuals)")
plt.title("Fitted vs Residuals")
plt.show()
```



*# Noktalar 0 etrafında rastgele dağılmışsa → lineerlik ve hataların ortal
Desen (yay, U, ters U, fan şekli) varsa model formu veya homoskedastisi*



In [17]: *# Normal Dağılım Varsayımı – Histogram + Q-Q Plot*

```
# Histogram + KDE
sns.histplot(df["residuals"], kde=True)
plt.title("Artıkların Dağılımı")
plt.show()

# Q-Q Plot
sm.qqplot(df["residuals"], line="45")
plt.title("Q-Q Plot (Artıklar)")
plt.show()
```

```
In [19]: # Homoskedastisite – Breusch-Pagan Testi

from statsmodels.stats.diagnostic import het_breuschpagan

resid = df["residuals"]
```

```
bp_test = het_breuschpagan(resid, X_const)

bp_labels = ["LM Stat", "LM p-value", "F-Stat", "F p-value"]
dict(zip(bp_labels, bp_test))

# LM p-value veya F p-value < 0.05 → heteroskedastisite olabilir.
# p-value > 0.05 → homoskedastisite varsayımını reddetmiyoruz (yani kabul
```

```
Out[19]: {'LM Stat': 1.5324580357720219,
          'LM p-value': 0.674799546671413,
          'F-Stat': 0.504468341168277,
          'F p-value': 0.6796354238596474}
```

```
In [20]: # Bağımsızlık Varsayımı – Durbin-Watson

from statsmodels.stats.stattools import durbin_watson

dw = durbin_watson(df["residuals"])
dw

# DW ≈ 2 → otokorelasyon yok (iyi).
# 0'a yakın → pozitif otokorelasyon
# 4'e yakın → negatif otokorelasyon
```

```
Out[20]: 1.8792820018127374
```

```
In [23]: # Multicollinearity – VIF (Variance Inflation Factor)

from statsmodels.stats.outliers_influence import variance_inflation_factor

vif_data = pd.DataFrame()
vif_data["feature"] = X_const.columns
vif_data["VIF"] = [variance_inflation_factor(X_const.values, i)
                   for i in range(X_const.shape[1])]

vif_data

# VIF ≈ 1–5 → sorun yok
# VIF > 10 → ciddi multicollinearity şüphesi
# Intercept'in VIF'i genellikle yorumlanmaz.
```

```
Out[23]:
```

	feature	VIF
0	const	10.899557
1	TV	1.003229
2	Radyo	1.016680
3	Sosyal	1.018122

```
In [22]: X_const.shape
```

```
Out[22]: (200, 4)
```

```
variance_inflation_factor(X_const.values, i)
```

- inci sütunu bağımlı değişken olarak seçer
- diğer sütunları bağımsız değişken olarak alır

- regresyon kurur
- R^2 hesaplar
- sonra VIF'i hesaplar

$$\text{VIF}_j = \frac{1}{1-R_j^2}$$

In []:

In []:

In []: