

SÜLEYMAN DEMİREL ÜNİVERSİTESİ
MÜHENDİSLİK FAKÜLTESİ
BİLGİSAYAR MÜHENDİSLİĞİ BÖLÜMÜ
VERİ MADENCİLİĞİ FİNAL SINAV CEVAP ANAHTARI

Sınav Yönergesi:

1. Her sorunun cevabı altındaki boşluğa yapılacaktır.
2. Defter kitap açıktır. Not alışverişi yasaktır.
3. Sınav süresi 40 dakikadır

ADI SOYADI:.....NO:.....

1.

```
dogs = pd.DataFrame([
{"id": 123, "yaş": 4, "renk": "kahverengi", "kürk": "tüylü",
"isim": "odie"},
{"id": 456, "yaş": 3, "renk": "gri", "kürk": "kısa",
"isim": "gabe"},
{"id": 821, "yaş": 6, "renk": "altın", "kürk": "kıvrırcık",
"isim": "samosa"},
{"id": 198, "yaş": 4, "renk": "gri", "kürk": "tüylü",
"isim": "gabe"},
{"id": 3, "yaş": 2, "renk": "siyah", "kürk": "kıvrırcık",
"isim": "bob barker"},
{"id": 42, "yaş": 5, "renk": "kahverengi", "kürk": "kıvrırcık",
"isim": "odie"}
]).set_index('id')
```

Aşağıdaki soruları yandaki kod bloğuna göre cevaplayınız? Her soru tek kod satırı ile cevaplanmalıdır.

- a) (5p)** Veteriner muayenehanesini isimleri farklı kaç farklı köpeğin ziyaret ettiğini gösteren kodu yazınız?

dogs["isim"].nunique()

- b) (10p)** Veteriner muayenehanesini ziyaret eden en yaşlı köpeğin adını ekrana basan kodu yazınız?

dogs[dogs["yaş"].max() == dogs["yaş"]]["isim"]

- c) (10p)** Köpekler arasındaki en yaygın kürk rengini ekrana basan kodu yazınız?

dogs.groupby("kürk").count()["yaş"].sort_values(ascending=False).index[0]

- d) (10p)** Aşağıdaki çıktıyı elde etmek için gerekli kodu yazınız?

	kürk	kısa	kıvrırcık	tüylü
renk				
altın	NaN	1.0	NaN	
gri	1.0	NaN	1.0	
kahverengi	NaN	1.0	1.0	
siyah	NaN	1.0	NaN	

```
pd.pivot_table(dogs,
index = "renk",
columns = "kürk",
values = "isim",
aggfunc = "count")
```

- e) (15p)** İsmi içerisinde "a" harfi geçen köpeklerden en yaşlının kürk tipini ekrana basan kodu yazınız?

dogs[dogs["yaş"] == dogs[dogs["isim"].str.contains("a")]["yaş"].max()]["kürk"]

2.

```
df = pd.read_csv("resources/diabetes.csv")
df
```

	Seker_Test	Kan_Basinci	Cilt_Kalinligi	Insulin	Vucut_Kitle_Indeksi	Soy_Iliski_Katsayisi	Yas	Sonuc
0	148	72	35	0	33.6	0.627	50	1
1	85	66	29	0	26.6	0.351	31	0
2	183	64	0	0	23.3	0.672	32	1
3	89	66	23	94	28.1	0.167	21	0
4	137	40	35	168	43.1	2.288	33	1
...	...	...	...	...	...	...	...	...
763	101	76	48	180	32.9	0.171	63	0
764	122	70	27	0	36.8	0.340	27	0
765	121	72	23	112	26.2	0.245	30	0
766	126	60	0	0	30.1	0.349	47	1
767	93	70	31	0	30.4	0.315	23	0

768 rows x 8 columns

```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 768 entries, 0 to 767
Data columns (total 8 columns):
#   Column              Non-Null Count  Dtype
---  -
0   Seker_Test          768 non-null   int64
1   Kan_Basinci         768 non-null   int64
2   Cilt_Kalinligi      768 non-null   int64
3   Insulin             768 non-null   int64
4   Vucut_Kitle_Indeksi 768 non-null   float64
5   Soy_Iliski_Katsayisi 768 non-null   float64
6   Yas                 768 non-null   int64
7   Sonuc               768 non-null   int64
dtypes: float64(2), int64(6)
memory usage: 48.1 KB
```

Aşağıdaki soruları yukarıdaki bilgiler dahilinde cevaplayınız?


a) (5p) Yukarıdaki bilgiler ışığında bu veri setinde hangi modelleme tekniği uygulanmalıdır?

Sınıflandırma ya da görülen tekniklerden Decision Tree

b) (10p) Sonuç alanında hangi veri türünden kaç veri olduğunu gösteren grafiği çizen kodu yazınız?

sns.countplot(data=df, x="Sonuc")

c) (10p) Aşağıdaki grafiği yorumlayınız?



Korelasyon matrisi incelendiğinde çıkış değişkeni sonuç ile giriş değişkenleri arasında yüksek bir ilişki olmadığı görülmektedir. En yüksek ilişkiye Seker_Test değişkeni sahiptir. Daha sonra Vucut_Kitle_Indeksi ve Yas değişkenleri takip etmektedir. Giriş değişkenleri arasında çoklu bağlantı problemi bulunmamaktadır. Kan_Basinci ve Cilt_Kalinligi değişkenlerinin çıkış üzerinde etkisi çok azdır. Bu nedenle model kurulurken kullanılmayabilir.

d) (25p) Gerekli modeli kurmak ve kurulan modelin başarısını ölçmek için gerekli kodları yazınız?

y = df["Sonuc"]

X = df.drop("Sonuc", axis=1)

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42)

model = DecisionTreeClassifier()

model.fit(X_train, y_train)

y_predict = model.predict(X_test)

confusion_matrix(y_test, y_predict)